

Projektdokumentation

BA-Beschäftigungsstatistik (CSV → MySQL) – Option B

Frauen | Deutsche vs. Ausländer | Bundesland | Berufsabschluss | SvB

Projekt	BA-Beschäftigungsstatistik – SvB (Frauen)
Auftraggeber	Landesstelle für Arbeitsmarktmonitoring & Integrationsberichterstattung
Schema (MySQL)	ba_svb_frauen
Tabellen	ba_raw (Staging), ba_clean (Fakt), dim_bundesland (Dimension)
Zeitraum	2022-01 bis 2025-06 (42 Monate)
Körnung (Grain)	Monat × Bundesland × Berufsabschluss × Staatsangehörigkeit (jeweils Frauen)
Sollumfang	4032 Zeilen (42 × 16 × 3 × 2)
Meilenstein	ETL v1 abgeschlossen: Import → Staging → Cleaning → Fakt/Dim-Modell → Quality Checks bestanden

Inhalt

1. Ziel und Fragestellung	3
Scope (Option B):.....	3
2. Datenquelle und CSV-Format	3
3. Erwartete Datenmenge (Soll)	3
4. Datenbank-Setup (MySQL)	3
5. Datenmodell (EER / Tabellen)	4
5.1 ba_raw (Staging).....	4
5.2 dim_bundesland (Dimension)	4
5.3 ba_clean (Faktentabelle)	4
Granularität (Faktgrain):.....	4
6. ETL-Pipeline (Import → Cleaning → Rebuild).....	4
6.1 Import in ba_raw (Staging).....	4
6.2 Normalisierung (Transformation in SQL).....	4
6.3 Rebuild von ba_clean (deterministisch)	4
7. Datenqualitätschecks (Definition + Sollwerte)	5
8. Semantic Layer und KPI-Logik (Views).....	5
8.1 Base View	5
8.2 KPI Views	5
Interpretationshinweise:	5
8.3 Feature Engineering & Index-/Trenddarstellung (Ergänzung nach Feedback).....	5
9. Skriptstruktur (00–07) und Run-Order	6
9.1 Dateien	6
9.2 Empfohlene Run-Order	6
10. Lessons Learned / Risiken.....	7
11. Reporting (Abgabe)	7
Tag 4 – Ergänzungen (Artefakte & Nachweis)	8
Tag 5 – Ergänzungen (Visualisierung, Storytelling & PPT-Ready Charts)	8
Tag 6 – Storytelling, PPT-Finalisierung & Reporting-Validierung (ohne Appendix)	9
Tag 7 – Finalisierung Präsentation & Abgabe (2026-02-02).....	11
Anhang A: Bundesländer-Schlüssel (Referenz)	13
Anhang B: Glossar – Spaltennamen & Bedeutung (Views/Reports)	13

1. Ziel und Fragestellung

Ziel ist der reproduzierbare Aufbau einer analysefähigen MySQL-Datenbasis aus einem BA-CSV-Export. Im Fokus steht die Kennzahl SvB (Sozialversicherungspflichtig Beschäftigte) für Frauen – vergleichend nach Staatsangehörigkeit (Deutsche vs. Ausländer) sowie nach Bundesland und Berufsabschluss.

Scope (Option B):

- Geschlecht: nur Frauen
- Staatsangehörigkeit: Deutsche vs. Ausländer
- Dimensionen: Bundesland, Berufsabschluss
- Kennzahl: SvB

2. Datenquelle und CSV-Format

Datenquelle ist eine CSV-Datei (BA-Beschäftigungsstatistik) mit folgenden Eigenschaften:

- Trennzeichen: ','
- Header: Stichtag;Geschlecht;Staatsangehörigkeit;Bundesland
Schlüssel;Bundesland;Berufsabschluss;SvB
- SvB enthält Tausenderpunkte (z. B. '11.810') und wird im Rebuild zu INT normalisiert.
- Bundesland Schlüssel muss 7-stellig bleiben (führende Nullen relevant).
- Beim Import via Workbench kann Mojibake auftreten (z. B. 'AuslÃ¼nder', 'Baden-WÃ¼rttemberg').

3. Erwartete Datenmenge (Soll)

Herleitung des Sollumfangs:

- 42 Monate (2022-01 bis 2025-06)
- 16 Bundesländer
- 3 Ausprägungen Berufsabschluss
- 2 Ausprägungen Staatsangehörigkeit (Deutsche/Ausländer)

Soll: $42 \times 16 \times 3 \times 2 = 4032$ Zeilen.

4. Datenbank-Setup (MySQL)

Technisches Setup (lokale MySQL-Instanz in MySQL Workbench):

- Schema: ba_svb_frauen (Default Charset/Collation: utf8mb4 / utf8mb4_0900_ai_ci).
- Importtool: MySQL Workbench (Table Data Import Wizard).
- Hinweis: LOAD DATA (LOCAL) INFILE war in dieser Umgebung restriktionsbedingt nicht zuverlässig nutzbar.
- Workbench-Hinweis: Für Skripte bevorzugt „Execute Selection“ statt „Execute All“.

5. Datenmodell (EER / Tabellen)

Das Modell folgt dem Prinzip Staging → Fakt/Dimension:

5.1 ba_raw (Staging)

- 1:1 Import aus CSV; alle Felder als VARCHAR/Text.
- Zweck: Rohdaten unverändert speichern (auch bei Encoding-Problemen).

5.2 dim_bundesland (Dimension)

- Referenztable mit 16 Bundesländern (bundesland_schluesel CHAR(7) + kanonischer Name).
- Zweck: korrekte Schlüssel validieren und saubere Bundeslandnamen liefern (Encoding-unabhängig).

5.3 ba_clean (Faktentabelle)

- Typisierte, bereinigte Daten für Analysen.
- stichtag: DATE (Monatsanfang, z. B. 2025-06-01), stichtag_label: Original (z. B. 'Jun 25').
- staatsangehoerigkeit: normalisiert auf genau {'Deutsche', 'Ausländer'}.
- bundesland_schluesel: CHAR(7) (führende Nullen erhalten).
- svb: INT UNSIGNED (Tausenderpunkte entfernt).
- bundesland: kanonisch aus dim_bundesland (verhindert Mojibake in Analyse).

Granularität (Faktgrain):

Ein Datensatz pro Kombination aus (Monat, Geschlecht, Staatsangehörigkeit, Bundesland, Berufsabschluss).

6. ETL-Pipeline (Import → Cleaning → Rebuild)

6.1 Import in ba_raw (Staging)

- Workbench → Table Data Import Wizard → Ziel: ba_svb_frauen.ba_raw.
- CSV-Settings: Separator ';', Header vorhanden.
- Nach Import: SELECT COUNT(*) FROM ba_raw; (Soll: 4032).

6.2 Normalisierung (Transformation in SQL)

- ba_raw darf „dirty“ bleiben; Normalisierung wird im Rebuild abgefangen.
- Staatsangehörigkeit-Mapping inkl. Varianten: 'Ausländer', 'Auslaender', 'AuslÃ¤nder' → 'Ausländer'.
- Bundesland-Schlüssel: LPAD auf 7 Stellen; bekannte Fehlcodierungen (z. B. 8000000 → 0800000) werden abgefangen.
- SvB: Entfernen von '.', ',', Leerzeichen → CAST zu UNSIGNED.
- Bundeslandname wird aus dim_bundesland gezogen (kanonisch).

6.3 Rebuild von ba_clean (deterministisch)

- TRUNCATE ba_clean;
- INSERT INTO ba_clean ... SELECT ... FROM ba_raw (inkl. Parsing/Mappings).
- JOIN dim_bundesland stellt sicher: nur gültige 16 Keys + saubere Namen.

7. Datenqualitätschecks (Definition + Sollwerte)

Nach jedem Rebuild gelten folgende Sollwerte als Abnahme:

- Rowcount: ba_clean = 4032
- Staatsangehörigkeit: 2016 Deutsche / 2016 Ausländer
- Zeitabdeckung: 42 Monate; min_date=2022-01-01, max_date=2025-06-01
- Bundesländer: 16 Schlüssel; min_key=0100000, max_key=1600000
- Referenzcheck: ba_clean.bundesland entspricht dim_bundesland.bundesland
- Duplikate auf Faktgrain = 0

8. Semantic Layer und KPI-Logik (Views)

Zur Analyse wird ein Semantic Layer als Views aufgebaut, damit Report-Queries stabil und lesbar sind.

8.1 Base View

- vw_ba_clean_base: standardisierte Zeitattribute (ym=YYYY-MM, jahr, monat) + Dimensionen + svb.
- vw_ba_clean_enriched → angereichert (z. B. Labels, zusätzliche Felder, Join-Infos)

8.2 KPI Views

- vw_kpi_total_by_month_nat: Monatssumme SvB nach Staatsangehörigkeit.
- vw_kpi_bl_by_month_nat: Monatssumme SvB nach Bundesland und Staatsangehörigkeit.
- vw_kpi_abschluss_by_month_nat: Monatssumme SvB nach Berufsabschluss und Staatsangehörigkeit.
- vw_kpi_share_auslaender_total: Anteil Ausländerinnen an Gesamt-SvB pro Monat.
- vw_kpi_gap_nat_by_bl_month: Gap je Monat und Bundesland = SvB(Ausländer) – SvB(Deutsche).
- vw_kpi_yoy_total_nat: YoY-Veränderung (absolut und prozentual) je Staatsangehörigkeit.

Interpretationshinweise:

- share_auslaender ist ein Anteil (0–1). Beispiel: 0,1178 = 11,78%.
- gap_ausl_minus_dt kann negativ sein: Dann ist SvB(Ausländer) kleiner als SvB(Deutsche) – das ist kein Fehler, sondern Ergebnis der Differenzbildung.

8.3 Feature Engineering & Index-/Trenddarstellung (Ergänzung nach Feedback)

Um die Analysen für Stakeholder verständlicher zu machen und „Feature Engineering“ im Projekt klar sichtbar nachzuweisen, wurden zusätzliche abgeleitete Merkmale (Features) sowie Trenddarstellungen in der Semantic Layer ergänzt.

Feature Engineering (Enrichment Layer)

Neben den typisierten Kernfeldern aus ba_clean werden zusätzliche Analysefeatures bereitgestellt, um Zeitreihen robuster auswerten zu können:

- ym_key (z. B. 202506): numerischer Monatskey zur stabilen Sortierung/Joins
- months_since_2022_01: lineare Zeitachse (Monate seit Startmonat 2022-01), hilfreich für Trendmodelle und Visualisierung

Diese Features werden in einer eigenen Enrichment-View gekapselt (z. B. vw_ba_clean_enriched) und dienen als Grundlage für KPI- und Trendberechnungen.

Index-/Trenddarstellung (Stakeholder-freundlich)

Zusätzlich zu absoluten Rohwerten (svb_sum) werden relative Entwicklungen und geglättete Trends bereitgestellt:

- **Index (Basis = erster Monat = 100):** erleichtert den Vergleich der Entwicklung zwischen Gruppen (Deutsche vs. Ausländerinnen), unabhängig vom absoluten Niveau.
Beispiel-Spalte: index_svb_2022_01_100
- **MA12 (12-Monats gleitender Durchschnitt):** reduziert saisonale Schwankungen und zeigt den langfristigen Trend.
Beispiel-Spalte: ma12_svb_sum
- **Anteil Ausländerinnen (Trendpaket):** Anteil als Prozent + MA12 + Index für Präsentationscharts:
 - share_auslaender_pct
 - ma12_share_auslaender_pct
 - index_share_2022_01_100

Visualisierung (Excel)

Die Trend-Outputs wurden so aufgebaut, dass sie direkt als **Liniendiagramme in Excel** verwendet werden können:

- Index-Zeitreihe Deutsche vs. Ausländerinnen (2 Linien)
- Anteil Ausländerinnen (%) plus MA12 (glatter Trend)

Hinweis YoY: Für die ersten 12 Monate sind yoy_abs und yoy_pct erwartungsgemäß NULL, da kein Vorjahresvergleichswert (LAG 12) vorhanden ist.

9. Skriptstruktur (00–07) und Run-Order

SQL-Dateien sind modular getrennt, um „Execute All“-Risiken zu minimieren und Rebuilds reproduzierbar zu halten.

9.1 Dateien

- **00_notes_debug.sql** — Notizen/Debug-Queries (nicht Teil des Standard-Runs).
- **00_reset_dev.sql** — DEV-Reset (DROP DATABASE) – nur bei Bedarf.
- **01_schema.sql** — DB + Tabellen (ba_raw, ba_clean) anlegen.
- **02_dim_bundesland.sql** — dim_bundesland erstellen und befüllen (16 Bundesländer).
- **03_rebuild_ba_clean.sql** — Deterministischer Rebuild: TRUNCATE + INSERT in ba_clean aus ba_raw + Join Dimension.
- **04_hardening_constraints.sql** — Constraints (UNIQUE/FK/CHECKs) – einmalig nach erfolgreicher Abnahme.
- **05_views_kpis.sql** — Semantic Layer + KPI Views (CREATE OR REPLACE).
- **06_quality_checks.sql** — Qualitätschecks (Sollwerte) – nach jedem Rebuild.
- **07_reporting.sql** — Report-Queries für Abgabe + Interpretation.

9.2 Empfohlene Run-Order

1. 01_schema.sql ausführen.

2. CSV-Import manuell in ba_raw (Workbench Import Wizard).
3. 02_dim_bundesland.sql ausführen.
4. 03_rebuild_ba_clean.sql ausführen.
5. 06_quality_checks.sql ausführen (Abnahme: Sollwerte).
6. 04_hardening_constraints.sql ausführen (nur 1x).
7. 05_views_kpis.sql ausführen.
8. 07_reporting.sql ausführen.

10. Lessons Learned / Risiken

- Encoding/Mojibake kann beim Wizard-Import auftreten: robust ist Transformation im Rebuild statt „Raw-Reparatur“.
- InnoDB Rows-Anzeige in Workbench ist nur Schätzwert: für Fakten COUNT(*) nutzen.
- Hardening-Statements (Constraints/Indizes) sind nicht idempotent: 04_hardening_constraints.sql nur einmal ausführen oder vorab gezielt dropen.
- Sicherheit: In Workbench „Execute Selection“ nutzen; destruktive Statements in 00_reset_dev.sql kapseln.
- Unique Key als Qualitätsbremse: Fehler 1062 („Duplicate entry ... for key uq_grain“) bedeutet, dass im Rebuild-SELECT Duplikate auf dem definierten Grain entstehen (häufig: ba_raw versehentlich doppelt importiert). → Preflight-Duplikat-Check (GROUP BY ... HAVING COUNT(*)>1) und ggf. ba_raw vor erneutem Import leeren.
- YoY-Kennzahlen: Für die ersten 12 Monate sind yoy_abs/yoy_pct erwartungsgemäß NULL (kein Vorjahresmonat vorhanden), weil LAG(...,12) dann keine Vergleichswerte liefert.

11. Reporting (Abgabe)

Für die Abgabe werden u. a. folgende Ausgaben erzeugt (07_reporting.sql):

- Top-5 Bundesländer je Staatsangehörigkeit im letzten Monat (DENSE_RANK).
- Anteil Ausländerinnen (SvB) je Monat (Zeitreihe).
- SvB nach Berufsabschluss im letzten Monat je Staatsangehörigkeit + optional Anteil Ausländer je Abschluss.
- YoY-Veränderung je Staatsangehörigkeit.
- **Index-/Trenddarstellung (neu):** Index-Report (Basis 2022-01=100) und MA12-Trend (Excel-Liniendiagramme)

Tag 4 – Ergänzungen (Artefakte & Nachweis)

Artefakte (heute erstellt / gesammelt):

- PPT-Skeleton angelegt/aktualisiert (inkl. Index/Appendix-Plan).
- Pro View: Screenshot aus MySQL Workbench (Result Grid) gespeichert.
- Pro View: CSV-Export gespeichert (Basis für Excel-Pivot & Diagramme).
- Reporting-Queries in 07_reporting.sql als Präsentations-Reports eingeordnet (z. B. Top-5, letzter Monat, Anteile, YoY/Index).

Ablage/Ordnerstruktur:

- PPT/ | Screenshots/ | Exports_CSV/ | Excel_Charts/

Entscheidung für Storytelling:

- Hauptteil = Charts + Implikationen (nicht-technisch), Appendix = Views/Reports als Nachweis & für Rückfragen.

Tag 5 – Ergänzungen (Visualisierung, Storytelling & PPT-Ready Charts)

Ziel: Ergebnispräsentation so aufbereiten, dass sie für Stakeholder ohne SQL-Vorwissen verständlich ist (Fokus: Interpretation/Implikationen statt Technik).

1) Storytelling-Entscheidung (Dozentenfeedback umgesetzt)

- **Hauptteil der PPT:** wenige Kerncharts + klare Argumentation (Was passiert? Warum relevant? Was folgt daraus?)
- **Appendix:** Views/Reports, technische Nachweise, Detailtabellen (für Rückfragen)

2) Excel-Visualisierung aus Views/Reports (CSV → Pivot → Chart)

Erzeugte/überarbeitete Visuals (PPT-ready):

- **Absolute Entwicklung (Niveau):** Zeitreihe SvB je Monat nach Staatsangehörigkeit
→ bevorzugt als **Liniendiagramm** (Monats-Säulen sind zu dicht und schwer lesbar).
- **Index-Entwicklung (Dynamik):** Index (Basis 2022-01 = 100) Deutsche vs. Ausländerinnen
→ **2-Linien-Chart** als zentrale Story-Folie („relative Wachstumsdynamik unabhängig vom Niveau“).
- **Qualifikationsstruktur (Komposition):** Verteilung nach Berufsabschluss (gesamt + nach Staatsangehörigkeit)
→ geeignet als **100% gestapelter Balken** oder gruppierte Balken (je nach Folienziel).

- **Bundesländer-Ranking (Top/Bottom):** BL nach SvB im letzten Monat (oder Index-Ranking)
→ **horizontale Balken**, absteigend sortiert, schnell interpretierbar.

3) Visual-Standards (Konsistenz über alle Charts)

- Farbkonzept: **Deutsche = Orange, Ausländerinnen = Blau**
- PivotSortierung für Rankings: **absteigend nach svb_sum**
- Charttitel so gestaltet, dass Filter/Gruppe eindeutig erkennbar ist (z. B. „Deutsche – SvB nach Bundesland (Jun 2025)“)
- Achsen/Lesbarkeit: zu viele Kategorien → Aggregation/Filter (z. B. Jahre statt 42 Monate für Säulencharts)

4) Nutzen für Präsentation & Abgabe

- Charts sind so aufgebaut, dass sie direkt in PPT übernommen werden können.
- Die Kombination **Niveau (absolute SvB) + Dynamik (Index) + Komposition (Berufsabschluss) + Region (BL-Ranking)** bildet eine „Business-Story“:
Wie groß? Wie entwickelt? Wodurch geprägt? Wo regional auffällig? Was folgt daraus?

Tag 6 – Storytelling, PPT-Finalisierung & Reporting-Validierung (ohne Appendix)

Ziel (heute): Ergebnis-PPT auf Storytelling trimmen (publikumsfreundlich), Charts finalisieren, Aussagen ausschließlich über vorhandene **Views + 07_reporting.sql** begründen, Abgabe-Check am Tagesende.

1) Scope-/Zeitraum-Entscheidung (für Präsentation)

- **Präsentationszeitraum: 2022–2024** (stabiler Vergleich über volle Jahre).
- **2025 H1 (Jan–Jun) nicht als „vollständiges Jahr“ interpretiert** (nur Halbjahresstand).
→ 2025 kann **optional** in Charts sichtbar sein, wird aber **nicht als Jahresvergleich** bewertet.
→ Detailwerte bleiben im Datensatz/Views vorhanden und können bei Nachfragen gezeigt werden.

2) Storytelling-Logik der PPT (Analyse statt Technik)

Die Präsentation wurde so aufgebaut, dass sie für ein Publikum ohne SQL-Vorwissen verständlich ist:

- Einstieg über **absolute Entwicklung** (Niveau und Trend).
- Danach Strukturfrage: **Wie verteilt sich SvB nach Berufsabschluss** (gesamt & nach Nationalität).
- Danach Dynamik: **Index (Basis 2022-01=100)** für vergleichbares Wachstum (Deutsche vs. Ausländerinnen).

- Regionaler Fokus: **Bundesländer Top/Bottom** (Niveau und/oder Wachstum).
- **Kein Appendix:** technische Nachweise (Views/Reports) werden im **Sprechtext** bzw. in der Dokumentation begründet.

3) Genutzte Datenbasis (SQL-sauber, nur Views/Reports)

Für alle Aussagen wurden ausschließlich folgende Artefakte verwendet:

- **Views (Semantic Layer):**
 - vw_kpi_total_by_month_nat (absolute SvB-Entwicklung je Monat & Staatsangehörigkeit)
 - vw_kpi_abschluss_by_month_nat (SvB nach Berufsabschluss & Staatsangehörigkeit)
 - vw_kpi_index_total_nat (Index: Basis 2022-01 = 100 je Staatsangehörigkeit)
 - vw_kpi_share_auslaender_trend (Anteil Ausländerinnen: Prozent + MA12 + Index)
 - vw_kpi_bl_by_month_nat (SvB je Bundesland & Staatsangehörigkeit)
 - vw_kpi_gap_nat_by_bl_month (Gap = SvB(Ausländerinnen) – SvB(Deutsche) je BL & Monat)
 - vw_kpi_yoy_total_nat (YoY absolut & prozentual je Staatsangehörigkeit)
- **Reports aus 07_reporting.sql (Abgabe-Outputs):**
 - Report 1–6 (Top5 BL, Anteil, Abschluss-Letzter Monat, YoY, Index, Anteil+MA12+Index)
 - **Neu ergänzt/konzeptionell sauber:** *Report 7 – Wachstumsranking (BL)* als Ableitung auf Basis vorhandener Views (siehe unten).

4) Excel/Charts – Umsetzung (aus CSV-Exports der Views)

Heute wurden Diagramme aus den CSV-Exports gebaut (Pivot-basiert):

- **Absolute Entwicklung (Linie statt Säulen):**
Quelle: vw_kpi_total_by_month_nat → Liniendiagramm (2 Linien: Deutsche, Ausländerinnen)
Begründung: Säulen je Monat waren visuell überladen; Linie zeigt Trend klarer.
- **Berufsabschluss-Verteilung (Gruppierte Säulen):**
Quelle: vw_kpi_abschluss_by_month_nat → gruppierte Säulen je Berufsabschluss, Serien nach Staatsangehörigkeit.
Interpretation: sehr hoher Anteil „Anerkannter Berufsabschluss“ → stabilitätsnahes Qualifikationsprofil; „Ohne Berufsabschluss“ bei Ausländerinnen im Verhältnis sichtbar (Integrations-/Qualifikationshebel).

- **Index & Wachstum (2 Linien):**
Quelle: vw_kpi_index_total_nat bzw. Report 5 → Index-Linie (Deutsche vs. Ausländerinnen).
Nutzen: Wachstum vergleichbar trotz unterschiedlicher Ausgangsniveaus.
- **Regionaler Fokus (Balken):**
Quelle: vw_kpi_gap_nat_by_bl_month (Stand letzter Monat) → Balken nach Größe sortiert.
Aussage: größte/kleinste Abstände je BL als Priorisierung für Monitoring.

5) Reporting-Erweiterung (nur SQL, keine externen Tools)

Report 7 – Wachstumsranking Bundesländer (SQL-sauber) wurde definiert, um Aussagen wie „BL X wächst am stärksten“ nachvollziehbar aus den Views abzuleiten.

- Grundlage: vw_kpi_bl_by_month_nat (Zeitreihe pro BL & Staatsangehörigkeit).
- Kennzahl: Wachstum über Zeitraum via Index oder Differenz (Start vs. Ende), Ranking per Window-Funktion.
- Ergebnis dient als **Begründung** für regionale Story-Folien.

6) Deliverables-Check (Abgabeordner)

Am Tagesende wurde geprüft:

- SQL-Dateien 00–07 vollständig + lauffähig (Run-Order dokumentiert).
- Views vorhanden (SHOW FULL TABLES WHERE Table_type='VIEW').
- Reporting (07) liefert reproduzierbare Outputs.
- PPT final (Storytelling, Charts statt Technik-Screens).
- CSV-Exports liegen vor (Nachweisbasis für Excel-Charts).

Tag 7 – Finalisierung Präsentation & Abgabe (2026-02-02)

Am letzten Projekttag lag der Schwerpunkt auf der zielgruppenorientierten Kommunikation der Analyseergebnisse sowie auf der Abgabequalität der Artefakte. Die Präsentation wurde in eine nachvollziehbare Storyline überführt (Bestände → Anteil → Index/Dynamik → Qualifikationsstruktur → regionale Perspektive → Implikationen). Der Vortragstext wurde so ausgearbeitet, dass er ohne technisches Vorwissen verständlich bleibt und die Ergebnisse als Entscheidungsgrundlage für Monitoring und Maßnahmenplanung beschreibt.

Ergänzend wurden die Handlungsempfehlungen präzisiert: (1) standardisiertes KPI-Set für monatliches Monitoring (Bestand, Anteil, Index/YoY), (2) qualifikationsbezogene Maßnahmenlogik mit Fokus auf Anerkennung/Nachqualifizierung, (3) gezielte Beobachtung des Segments „Ohne Berufsabschluss“ als potenzielles Barrieren-/Risikosegment, (4) regionale Priorisierung entlang Größenordnungen und

Strukturunterschieden, sowie (5) standardisierter Drilldown nach Bundesland × Berufsabschluss × Staatsangehörigkeit.

Zur Vermeidung von Fehlinterpretationen wurden Interpretationsregeln ergänzt: Staatsangehörigkeit ist eine amtliche Kategorie (Pass), Einbürgerung kann die Zuordnung über die Zeit beeinflussen, und die Ergebnisse zeigen Muster (keine Ursachen). Für Jahresvergleiche wurden vollständige Jahre (2022–2024) priorisiert, während 2025 (1. Halbjahr) als Teiljahr methodisch gekennzeichnet wurde.

Abschließend wurde das Abgabe-Paket final geprüft (Dateistruktur, Dateinamen, Lesbarkeit der Charts, Konsistenz der Inhalte) und vollständig abgegeben (Präsentation, kommentiertes SQL-Skript, Dokumentation; optional Exporte/Screenshots als Nachweis).

Anhang A: Bundesländer-Schlüssel (Referenz)

Bundesland-Schlüssel (7-stellig)	Bundesland
0100000	Schleswig-Holstein
0200000	Hamburg
0300000	Niedersachsen
0400000	Bremen
0500000	Nordrhein-Westfalen
0600000	Hessen
0700000	Rheinland-Pfalz
0800000	Baden-Württemberg
0900000	Bayern
1000000	Saarland
1100000	Berlin
1200000	Brandenburg
1300000	Mecklenburg-Vorpommern
1400000	Sachsen
1500000	Sachsen-Anhalt
1600000	Thüringen

Anhang B: Glossar – Spaltennamen & Bedeutung (Views/Reports)

- **Share** ist ein Anteil: Wie viel Prozent der gesamten SvB entfallen auf Ausländerinnen?
- **Gap** ist eine Differenz: *Ausländerinnen minus Deutsche* – negative Werte sind normal und bedeuten „Deutsche sind mehr“.
- **YoY** ist Vorjahresvergleich: *gleicher Monat im Vorjahr*; die ersten 12 Monate haben oft NULL, weil der Vorjahreswert fehlt.

Spaltenname	Bedeutung	Beispiel	Interpretation / Hinweis
stichtag	Monatsdatum (immer 1. des Monats)	2025-06-01	Steht für „Juni 2025“ (Monatsanfang, sauber für Zeitreihen)
ym	Jahr-Monat als Textlabel	2025-06	Praktisch für Charts/Grouping (x-Achse)
jahr	Jahr (Zahl)	2025	Ableitung aus stichtag
monat	Monat (Zahl 1–12)	6	Ableitung aus stichtag
geschlecht	Geschlecht (Scope fix)	Frauen	In Option B immer konstant „Frauen“
staatsangehoerigkeit	Kategorie Nationalität	Deutsche,	Normalisiert (Mojibake/Schreibvarianten werden

Spaltenname	Bedeutung	Beispiel	Interpretation / Hinweis
		Ausländer	gemappt)
bundesland_schluesel	7-stelliger BL-Schlüssel	0100000	Führende Nullen bleiben erhalten (wichtig für Referenzen/FK)
bundesland	Bundeslandname	Baden- Württemberg	Kommt kanonisch aus dim_bundesland (Umlaute korrekt)
berufsabschluss	Abschlusskategorie	z. B. Ohne Berufsabschluss	3 Kategorien im Datensatz (wie in CSV)
svb	SvB als Zahl (int)	11810	Tausenderpunkte entfernt („11.810“ → 11810)
svb_sum	Summe der SvB über eine Gruppierung	13306800	Ergebnis nach GROUP BY (z. B. pro Monat/Nationalität)
svb_auslaender	SvB-Summe nur für Ausländerinnen	1775710	Teilkomponente in Share-View (numerator)
svb_total	SvB-Summe Deutsche + Ausländerinnen	15075150	Gesamt (denominator)
share_auslaender	Anteil Ausländerinnen an Gesamt-SvB	0.1178	0–1 Skala → 0.1178 = 11,78%
share_auslaender_pct	Anteil in Prozent	11.78	Das ist nur share_auslaender * 100
gap_ausl_minus_dt	Differenz: Ausländerinnen – Deutsche	-406810	negativ = Deutsche > Ausländerinnen (kein Fehler)
svb_sum_prev_year	Vorjahreswert (gleicher Monat, 12 Monate zurück)	z. B. 1385740	Basis für YoY; NULL im ersten Jahr möglich
yoy_abs	Year-over-Year (absolut)	134360	svb_sum – svb_sum_prev_year
yoy_pct	Year-over-Year (prozentual)	9.70 (wenn schon *100) / 0.0970 (roh)	yoy_abs / svb_sum_prev_year; NULL für 2022 , weil kein Vorjahr im Datensatz vorhanden